

Отчёт по проекту: Прогноз глобальной температуры Земли

Студент: Куров Егор Группа: БИВ234

1. Введение и постановка задачи

Решил сделать прогноз среднемесячной температуры Земли по историческим данным. Идея простая: можно ли по температуре за прошлые месяцы предсказать, что будет в следующем.

Задача — регрессия, целевая переменная `LandAverageTemperature`.

Основная метрика — **MAE**, потому что она в градусах и сразу понятно, на сколько модель ошибается. RMSE и R^2 смотрел дополнительно, но ориентировался на MAE.

2. Поиск и описание данных

Взял датасет Berkeley Earth с Kaggle — там данные по температуре с 1750 по 2015 год.

- **Строк:** 3 192 (по месяцам)
- **Столбцов:** 9
- **Основные признаки:** дата, средняя температура суши, максимальная/минимальная, температура суши+океана

Данных не очень много, но для начала норм — главное, что длинный период, видно тренды.

3. Обработка и подготовка данных

Что сделал:

- Удалил 12 строк где не было целевой переменной
- Преобразовал дату в datetime
- Добавил `year`, `month`, `season` из даты
- Сделал лаги: `temp_lag1`, `temp_lag2`, `temp_lag3`, `temp_lag12`
- После сдвигов первые 12 строк выкинул, осталось 1 992

Сплит:

- Train: до 2000 года (1 812 строк)
- Val: 2001-2010 (120 строк)
- Test: после 2010 (60 строк)

Разбивал по времени, не случайно — чтобы не было утечки будущего в прошлое.

По графикам видно, что температура реально растёт с 1900-х, а по корреляции `temp_lag12` самый сильный признак (0.994).

4. Baseline-модель

В качестве baseline взял обычную линейную регрессию на признаках: `year`, `month`, `temp_lag1`, `temp_lag2`, `temp_lag12`.

Результаты на валидации:

Метрика	Значение
MAE	0.329 °C
RMSE	0.415 °C
R ²	0.990

Наивный прогноз (просто среднее) даёт MAE 3.8°C, так что модель реально работает.

5. Эксперименты

Эксперимент 1: Сравнение моделей

Гипотеза: Может, нелинейные модели дадут прирост.

Что сделал: Обучил Random Forest, XGBoost, LightGBM на тех же признаках, сравнил MAE.

Результат:

Модель	MAE (°C)	RMSE (°C)	R ²
Linear Regression	0.329	0.415	0.990
Random Forest	0.449	0.570	0.981
XGBoost	0.447	—	—
LightGBM	0.418	—	—

Вывод: Линейная регрессия всё равно лучшая. Видимо, зависимость тут почти линейная, сложные модели только переусложняют.

Эксперимент 2: Важность признаков

Гипотеза: temp_lag12 (год назад) — самый важный признак.

Проверка: Посмотрел на коэффициенты линейной регрессии.

Что вышло: $\text{Temperature} = -0.435 + 0.0006 \times \text{year} - 0.0095 \times \text{month} + 0.5865 \times \text{temp_lag1} - 0.3267 \times \text{temp_lag2} + 0.6531 \times \text{temp_lag12}$

temp_lag12 реально имеет самый большой коэффициент (0.65), потом temp_lag1 (0.59). year почти незаметен (0.0006), но положительный — типа глобальное потепление есть, но слабое.

Вывод: Гипотеза подтвердилась.

Эксперимент 3: Лишние лаги

Гипотеза: Добавить `temp_lag3` — станет лучше.

Проверка: Сравнил модель с `lag3` и без него.

Результат: Корреляция `lag3` с целевой — 0.012, качество модели не изменилось.

Вывод: `temp_lag3` не нужен, можно выкинуть.

Общая таблица

Эксперимент	Гипотеза	Подтвердилось?	MAE
Сравнение моделей	Нелинейные лучше	Нет	0.329
Важность признаков	<code>lag12</code> главный	Да	—
Добавление <code>lag3</code>	Улучшит модель	Нет	0.329

6. Финальная модель

Оставил **Linear Regression**. Причины:

- Лучшая метрика (MAE 0.33)
- Быстрая, простая, не надо подбирать параметры
- Можно объяснить каждый коэффициент

Что влияет на прогноз:

- `temp_lag12` (+0.65) — основной фактор, годовая сезонность
- `temp_lag1` (+0.59) — инерция от прошлого месяца
- `temp_lag2` (-0.33) — корректировка
- `year` (+0.0006) — слабый тренд потепления

- `month` (-0.01) — почти не влияет
-

7. Деплой

Сделал API на FastAPI, один эндпоинт `POST /predict` на порту 8000.

Пример запроса:

```
{
  "year": 2016,
  "month": 1,
  "temp_lag1": 0.5,
  "temp_lag2": 0.3,
  "temp_lag12": 0.8
}
```

Ответ:

```
{
  "predicted_temperature": 1.5718
}
```

Есть Dockerfile для контейнера.

Видео и скрины:

<https://drive.google.com/drive/folders/1o4oTrWdNlyBH9iEuntM6GH7bfSpVtXn9?usp=sharing>